

1^{re} - NSI - FICHE 6 - TYPES ET VALEURS DE BASE

ENCODAGE D'UN TEXTE - LES CHAINES DE CARACTÈRES

I. ENCODAGE D'UN TEXTE

1. Le code ASCII

On a vu précédemment que les ordinateurs ne savaient manipuler que des 0 et des 1. Il a donc été nécessaire pour pouvoir écrire des textes de traduire les caractères composant ces derniers en binaire. Ainsi, dans les années 1960, est apparu le code ASCII (American Standard Code for Information Interchange).

La norme ASCII utilise 7 bits et permet donc de coder 128 caractères (de 0 à 127).

Les codes 0 à 31 ne sont pas des caractères. On les appelle caractères de contrôle car ils permettent de faire des actions telles que : retour à la ligne (CR) et bip sonore (BEL).

les codes 48 à 57 représentent les chiffres, les codes 65 à 90 représentent les majuscules, les codes 97 à 122 représentent les minuscules, les derniers représentent les accolades, la tilde...

Decimal	Hex	Char	Decimal	Hex	Char	Decimal	Hex	Char	Decimal	Hex	Char
0	0	[NULL]	32	20	[SPACE]	64	40	@	96	60	`
1	1	[START OF HEADING]	33	21	!	65	41	A	97	61	a
2	2	[START OF TEXT]	34	22	"	66	42	B	98	62	b
3	3	[END OF TEXT]	35	23	#	67	43	C	99	63	c
4	4	[END OF TRANSMISSION]	36	24	\$	68	44	D	100	64	d
5	5	[ENQUIRY]	37	25	%	69	45	E	101	65	e
6	6	[ACKNOWLEDGE]	38	26	&	70	46	F	102	66	f
7	7	[BELL]	39	27	'	71	47	G	103	67	g
8	8	[BACKSPACE]	40	28	(	72	48	H	104	68	h
9	9	[HORIZONTAL TAB]	41	29	)	73	49	I	105	69	i
10	A	[LINE FEED]	42	2A	*	74	4A	J	106	6A	j
11	B	[VERTICAL TAB]	43	2B	+	75	4B	K	107	6B	k
12	C	[FORM FEED]	44	2C	,	76	4C	L	108	6C	l
13	D	[CARRIAGE RETURN]	45	2D	-	77	4D	M	109	6D	m
14	E	[SHIFT OUT]	46	2E	.	78	4E	N	110	6E	n
15	F	[SHIFT IN]	47	2F	/	79	4F	O	111	6F	o
16	10	[DATA LINK ESCAPE]	48	30	0	80	50	P	112	70	p
17	11	[DEVICE CONTROL 1]	49	31	1	81	51	Q	113	71	q
18	12	[DEVICE CONTROL 2]	50	32	2	82	52	R	114	72	r
19	13	[DEVICE CONTROL 3]	51	33	3	83	53	S	115	73	s
20	14	[DEVICE CONTROL 4]	52	34	4	84	54	T	116	74	t
21	15	[NEGATIVE ACKNOWLEDGE]	53	35	5	85	55	U	117	75	u
22	16	[SYNCHRONOUS IDLE]	54	36	6	86	56	V	118	76	v
23	17	[ENG OF TRANS. BLOCK]	55	37	7	87	57	W	119	77	w
24	18	[CANCEL]	56	38	8	88	58	X	120	78	x
25	19	[END OF MEDIUM]	57	39	9	89	59	Y	121	79	y
26	1A	[SUBSTITUTE]	58	3A	:	90	5A	Z	122	7A	z
27	1B	[ESCAPE]	59	3B	;	91	5B	[	123	7B	{
28	1C	[FILE SEPARATOR]	60	3C	<	92	5C	\	124	7C	
29	1D	[GROUP SEPARATOR]	61	3D	=	93	5D	]	125	7D	}
30	1E	[RECORD SEPARATOR]	62	3E	>	94	5E	^	126	7E	~
31	1F	[UNIT SEPARATOR]	63	3F	?	95	5F	_	127	7F	[DEL]

En Python, on peut trouver les correspondances entre code ASCII et caractère avec les fonctions ord("k") (donne le code ASCII de "k") et chr(84) (donne la lettre correspondant au code ASCII 84 : T).

Par exemple, si on veut trouver l'écriture binaire en ASCII du mot "Info", on commence à associer à chaque lettre son code ASCII. On transforme ce nombre en binaire.

Lettre	Code ASCII	Binaire
I	73	01001001
n		
f		
o		

Le mot "Info" est donc codé sur 32 bits soit 4 octets par :

.....

On se rend compte que, dans ce code là, les accents, les lettres spécifiques au français, l'espagnol... ne sont pas codées : SpÃ©cialitÃ© NumÃ©rique et sciences informatiques. Une des premières améliorations fut la norme ISO-8859-1.

2. La norme ISO-8859-1

Elle s'écrit sur 8 bits, elle permet l'affichage des caractères accentués mais ne permet pas l'écriture chinoise, de l'arabe...

Il a donc fallu établir un code plus large : la norme unicode

3. La norme unicode

La norme unicode permet l'encodage des caractères autres que ceux de l'alphabet latin. Les 128 premiers caractères restent compatibles avec l'ASCII. La table de correspondance de l'unicode est appelée Charset (Caractère-code).

Il existe plusieurs variantes de l'unicode : UTF-8 , UTF-16, UTF-32.

Les navigateurs internet utilisent le codage UTF-8.

L'encodage UTF-8 utilise entre 1 et 4 octets. Les octets ne sont pas remplis entièrement. Les bits de poids fort du premier octet forment une suite de 1 indiquant le nombre d'octets utilisés pour coder le caractère. Les octets suivants commencent tous par le bloc binaire 10.

Représentation binaire UTF-8	Signification	Caractères disponibles
0xxxxxxx	1 octet codant 1 à 7 bits	Latin de base (ASCII)
110xxxxx 10xxxxxx	2 octets codant 11 bits	Alphabets d'Europe et du Moyen-Orient
1110xxxx 10xxxxxx 10xxxxxx	3 octets codant 16 bits	Quasi-totalité des alphabets actuels
11110xxx 10xxxxxx 10xxxxxx 10xxxxxx	4 octets codant 21 bits	Tous les caractères

Pour plus de précision : <https://fr.wikipedia.org/wiki/Unicode>

4. Les erreurs d'encodage

Certaines fois lors de la lecture de documents, vous avez pu observer que les caractères accentués étaient représentés par des caractères spéciaux (A surmonté d'une tilde, c entouré...). Vous savez maintenant que ceci est dû à un problème d'encodage.

II. CHAINES DE CARACTÈRES

1. Rappels

Sous Python, les chaînes de caractères sont déclarées entre guillemets. Exemple : mois="janvier".

Attention ! La première lettre d'une chaîne de caractères a pour indice 0, la deuxième a pour indice 1... (Voir fiche 3.2)

2. Compléments à la fiche 3.2 : programmation

Commande	Effet
mot.upper()	Renvoie la chaîne mot en majuscule
mot.lower()	Renvoie la chaîne mot en minuscule
str(nb)	Renvoie une chaîne de caractères contenant l'écriture décimale du nombre nb
int(ch)	Transforme la chaîne ch en valeur numérique entière
float(ch)	Transforme la chaîne ch en valeur numérique flottante

III. EXERCICES

1. QCM Parmi les réponses, une seule est correcte.
 - a. Parmi les termes suivants, lequel n'a pas de lien avec le codage des caractères ?
 - i. ASCII ii. ANSI iii. UTF-8 iv. UTF-16
 - b. La chaîne de caractère `ch` a pour valeur "123456789". Que vaut `ch[7]+ch[8]` ?
 - i. 15 ii. 17 iii. "78" iv. "89"
2. Taille d'un fichier
 - a. Quelle est la taille (en ko) d'un fichier texte contenant 75 000 caractères ?
 - b. On tape la phrase "Bonjour à tous" dans un fichier créé avec Geany et enregistré avec l'extension .txt. Quelle est la taille de ce fichier quand on le sauvegarde sur le disque dur.
 - c. On tape la même chose avec la suite Open Office dans un fichier avec l'extension .odt. Commenter la différence avec la question précédente.
3. A l'aide de la table ASCII :
 - a. Convertir en binaire la phrase suivante : Il fait beau
 - b. Décoder : 01001100 01100101 00100000 01100011 01101000 01100001 01110100 00100000 01101101 01100001 01101110 01100111 01100101 00100000 01101100 01100001 00100000 01110011 01101111 01110101 01110010 01101001 01110011
4. Quand on est passé de la table ASCII à d'autres tables, le huitième bit a pu servir pour encoder plus de caractères. Combien de plus ?
5. Programmer une fonction **renverse**, prenant en paramètre une chaîne de caractères **mot** et renvoie cette chaîne de caractères en ordre inverse.

Exemple :

```
> > > renverse("")
""
> > > renverse("abc")
"cba"
> > > renverse("informatique")
"euqitamrofni"
```
6. Écrire une fonction **occurrences(caractere, chaine)** qui prend en paramètres **caractere**, une chaîne de caractère de longueur 1, et **chaine**, une chaîne de caractères.

Cette fonction renvoie le nombre d'occurrences de **caractere** dans **chaine**, c'est-à-dire le nombre de fois où **caractere** apparaît dans **chaine**.

Exemples :

```
> > > occurrences('e', "sciences")
2
> > > occurrences('i', "mississippi")
4
> > > occurrences('a', "mississippi")
0
```
7. Ecrire un programme où le joueur saisit un mot et l'ordinateur l'affiche en doublant toutes les voyelles. (Bonjour devient Boonjoouur)
8. Ecrire un programme qui demande une phrase à l'utilisateur et qui intercale une * entre chaque caractère. "Bonjour monde" devient "B*o*n*j*o*u*r* *m*o*n*d*e*"

9. Ecrire un programme :

- * Le joueur 1 entre un mot
- * Le joueur 2 propose une lettre
- * L'ordinateur indique si cette lettre est présente ou non et combien de fois elle apparaît.

10. On considère des chaînes de caractères contenant uniquement des majuscules et des caractères "*" appelées **mots à trous**.

Par exemple "INFO*MA*IQUE", "***I***E**" et "*S*" sont des mots à trous.

Programmer une fonction **correspond** qui :

- prend en paramètres deux chaînes de caractères **mot** et **mot_a_trous** où **mot_a_trous** est un mot à trous comme indiqué ci-dessus,
- renvoie :
 - ☞ True si on peut obtenir "mot" en remplaçant convenablement les caractères "*" de "mot_a_trous".
 - ☞ False sinon.

Exemple :

```
> > > correspond('INFORMATIQUE','INFO*MA*IQUE')
```

True

```
> > > correspond('AUTOMATIQUE', 'INFO*MA*IQUE')
```

False

```
> > > correspond('STOP', 'S*')
```

False

```
> > > correspond('AUTO', '*UT*')
```

True